

优化理论与算法

第六章 对偶理论

郭加熠 | 助理教授



目录

复习

问题重构

KKT 条件

灵敏度分析

拉格朗日函数 (Lagrangian)

标准形式问题 (不要求是凸的):

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

变量 $x \in \mathbb{R}^n$, 定义域 \mathcal{D} , 最优值为 p^*

拉格朗日函数: $L: \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$, 定义域为 $\text{dom } L = \mathcal{D} \times \mathbb{R}^m \times \mathbb{R}^p$, 其形式为:

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$

- ▶ 目标函数与约束函数的加权和
- ▶ λ_i, ν_i 分别是不等式约束 $f_i(x) \leq 0$ 与等式约束 $h_i(x) = 0$ 对应的拉格朗日乘子

拉格朗日对偶函数 (Lagrange Dual Function)

拉格朗日对偶函数: $g : \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$, 定义为:

$$\begin{aligned} g(\lambda, \nu) &= \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) \\ &= \inf_{x \in \mathcal{D}} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \right) \end{aligned}$$

- ▶ 函数 g 是凹函数, 但在某些 λ, ν 情况下可能为 $-\infty$
- ▶ 下界性质 (Lower bound property): 若 $\lambda \geq 0$, 则 $g(\lambda, \nu) \leq p^*$

证明: 若 \tilde{x} 是可行解, 且 $\lambda \geq 0$, 则有

$$f_0(\tilde{x}) \geq L(\tilde{x}, \lambda, \nu) \geq \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) = g(\lambda, \nu)$$

对所有可行的 \tilde{x} 取最小值, 可得: $p^* \geq g(\lambda, \nu)$

标准形式线性规划 (Standard Form LP)

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & Ax = b, \quad x \geq 0 \end{aligned}$$

拉格朗日函数: $L(x, \lambda, \nu) = c^T x + \nu^T (Ax - b) - \lambda^T x = -b^T \nu + (c + A^T \nu - \lambda)^T x$

L 是关于 x 的仿射函数, 因此拉格朗日对偶函数:

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu) = \begin{cases} -b^T \nu, & c + A^T \nu - \lambda = 0 \\ -\infty, & \text{否则} \end{cases}$$

► g 是定义在

$\{(\lambda, \nu) \mid c + A^T \nu - \lambda = 0\}$ 上的
线性函数, 因此是凹函数

► 下界性质 (lower bound property):

$$p^* \geq -b^T \nu \quad \text{if } c + A^T \nu \geq 0$$



对偶问题

拉格朗日对偶问题:

$$\max \quad g(\lambda, \nu)$$

$$\text{s.t.} \quad \lambda \geq 0$$

- ▶ 利用拉格朗日函数, 找到 p^* 最好的下界
- ▶ 对偶问题是**凸问题**, 最优值用 d^* 表示
- ▶ 如果 $(\lambda, \nu) \in \text{dom}(g)$ 且 $\lambda \geq 0$, 那么 (λ, ν) 是对偶问题**可行解**
- ▶ 常常将隐含约束 $(\lambda, \nu) \in \text{dom}(g)$ 显现写出

$$\min \quad c^T x$$

$$\text{s.t.} \quad Ax = b, \quad x \geq 0$$

$$\max \quad -b^T \nu$$

$$\text{s.t.} \quad A^T \nu + c \geq 0$$

弱对偶与强对偶 (Weak and Strong Duality)

弱对偶 (weak duality): $d^* \leq p^*$

► 总是成立 (无论问题是凸的还是非凸的)

► 可用于为困难问题提供非平凡的下界

► 例如, 求解如下 SDP 问题:

$$\max \quad -\mathbf{1}^T \nu$$

$$\text{s.t.} \quad W + \text{diag}(\nu) \succeq 0$$

强对偶 (strong duality): $d^* = p^*$

► 一般不成立

► 对于凸优化问题通常成立

► 保证强对偶成立的条件被称为: **约束资格条件 (constraint qualifications)**

强对偶的示例 (Examples with Strong Duality)

- 唯一的对偶最优解 (Unique Dual Optimal):

$$\min \quad \frac{1}{2}(x_1^2 + x_2^2)$$

$$\text{s.t.} \quad x_1 \leq 1$$

- 多个对偶最优解 (Multiple Dual Optimal):

$$\min \quad |x_1| - x_2 \quad \text{s.t.} \quad x_1 \leq 0, x_2 = 0$$

- 无对偶最优解 (No Dual Optimal):

$$\min \quad x \quad \text{s.t.} \quad x^2 \leq 0$$

类似地, $d^* = p^*$ 与原始问题是否有最优解无关。

一个具有强对偶的非凸问题

$$\begin{aligned} \min \quad & x^T A x + 2b^T x \\ \text{s.t.} \quad & x^T x \leq 1 \end{aligned}$$

由于 $A \not\succeq 0$, 该问题非凸。对偶函数 (Dual Function):

$$g(\lambda) = \inf_x (x^T (A + \lambda I) x + 2b^T x - \lambda)$$

- ▶ 若 $A + \lambda I \not\succeq 0$ 或 $A + \lambda I \succeq 0$ 且 $b \notin \mathcal{R}(A + \lambda I)$, 则 $g(\lambda) = -\infty$
- ▶ 否则, 最小值由 $x = -(A + \lambda I)^\dagger b$ 达到, 且 $g(\lambda) = -b^T (A + \lambda I)^\dagger b - \lambda$

对偶问题 (Dual Problem) 及等价 SDP 表达:

$$\begin{aligned} \max \quad & -b^T (A + \lambda I)^\dagger b - \lambda \\ \text{s.t.} \quad & A + \lambda I \succeq 0, \quad b \in \mathcal{R}(A + \lambda I) \end{aligned} \quad \begin{aligned} \max \quad & -t - \lambda \\ \text{s.t.} \quad & \begin{bmatrix} A + \lambda I & b \\ b^T & t \end{bmatrix} \succeq 0 \end{aligned}$$

即使原始问题不是凸的, 仍然可以实现强对偶 (证明并不容易)。



目录

复习

问题重构

KKT 条件

灵敏度分析



对偶与问题重构

- ▶ 一个问题的等价形式可能会导出非常不同的对偶问题；
- ▶ 当对偶问题难以推导或不具启发性时，重构原始问题可能会非常有用；

常见的重构方式

- ▶ 引入新变量和等式约束；
- ▶ 将显式约束转为隐式，或反之；
- ▶ 变换目标函数或约束函数，

例如：将 $f_0(x)$ 替换为 $\phi(f_0(x))$ ，其中 ϕ 是凸且单调递增的函数。

表示问题 (Representation Issue)

$$\begin{array}{ll}\text{minimize} & -x_2 \\ \text{subject to} & \|x\| \leq x_1\end{array}$$

$$x \in D, \quad D = \{(x_1, x_2) \mid x_2 \geq 0\}$$

- ▶ 放松不等式约束会得到一个对偶问题，其中 $d^* = -\infty$ ，而 $p^* = 0$ 。
- ▶ 但更仔细查看约束集合发现： $C = \{(x_1, x_2) \mid x_1 \geq 0, x_2 = 0\}$ ，写出等价问题

$$\begin{array}{ll}\text{minimize} & -x_2 \\ \text{subject to} & x_1 \geq 0, \quad x_2 = 0 \\ & x \in \mathbb{R}^2\end{array}$$

这个问题是没有对偶间隙的！

对偶间隙与约束的“表示形式”（约束的建模方式）密切相关



引入新变量与等式约束

$$\text{minimize } f_0(Ax + b)$$

- ▶ 对偶函数是常数: $g = \inf_x L(x) = \inf_x f_0(Ax + b) = p^*$
- ▶ 虽然满足强对偶性, 但此时对偶问题几乎无用

重写后的问题及其对偶问题:

$$\text{minimize } f_0(y)$$

$$\text{subject to } Ax + b - y = 0$$

$$\text{maximize } b^T \nu - f_0^*(\nu)$$

$$\text{subject to } A^T \nu = 0$$

对偶函数推导如下:

$$g(\nu) = \inf_{x,y} \left(f_0(y) - \nu^T y + \nu^T Ax + b^T \nu \right) = \begin{cases} -f_0^*(\nu) + b^T \nu & \text{if } A^T \nu = 0 \\ -\infty & \text{Otherwise} \end{cases}$$

范数逼近问题的对偶问题

范数逼近问题：最小化 $\|Ax - b\|$ 转成最小化 $\|Ax - b\|^2$

原问题：

$$\begin{aligned} & \text{minimize} && \|y\|^2 \\ & \text{subject to} && y = Ax - b \end{aligned}$$

对偶问题：

$$\begin{aligned} & \text{maximize} && b^T \nu - \frac{\|\nu\|^2}{4} \\ & \text{subject to} && A^T \nu = 0. \end{aligned}$$

推导：

$$\begin{aligned} g(\nu) &= \inf_{x,y} \left(\|y\|^2 + \nu^T y - \nu^T Ax + b^T \nu \right) \\ &= \begin{cases} b^T \nu + \inf_y (\|y\|^2 + \nu^T y) & \text{if } A^T \nu = 0 \\ -\infty & \text{o.w.} \end{cases} = \begin{cases} b^T \nu - \frac{\|\nu\|^2}{4} & \text{if } A^T \nu = 0 \\ -\infty & \text{o.w.} \end{cases} \end{aligned}$$



隐式约束

带有盒约束 (box constraints) 的线性规划：原始问题与对偶问题

$$\text{minimize } c^T x$$

$$\text{maximize } -b^T \nu - \mathbf{1}^T \lambda_1 - \mathbf{1}^T \lambda_2$$

$$\text{subject to } Ax = b$$

$$\text{subject to } c + A^T \nu + \lambda_1 - \lambda_2 = 0$$

$$-1 \leq x \leq 1$$

$$\lambda_1 \geq 0, \lambda_2 \geq 0$$

将盒约束隐式化后的重构问题：

$$\text{minimize } f_0(x) = \begin{cases} c^T x & -1 \leq x \leq 1 \\ \infty & \text{其他情况} \end{cases}$$

$$\text{subject to } Ax = b$$

$$\text{对偶函数: } g(\nu) = \inf_{-1 \leq x \leq 1} (c^T x + \nu^T (Ax - b)) = -b^T \nu - \|c + A^T \nu\|_1$$

$$\text{对偶问题: maximize } -b^T \nu - \|c + A^T \nu\|_1$$



目录

复习

问题重构

KKT 条件

灵敏度分析

互补松弛性 (Complementary Slackness)

假设强对偶成立, x^* 为原始问题最优解, (λ^*, ν^*) 为对偶问题最优解:

$$\begin{aligned} f_0(x^*) = g(\lambda^*, \nu^*) &= \inf_x \left(f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p \nu_i^* h_i(x) \right) \\ &\leq f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p \nu_i^* h_i(x^*) \\ &\leq f_0(x^*) \end{aligned}$$

因此, 两个不等式必须同时取等:

- ▶ x^* 使拉格朗日函数 $L(x, \lambda^*, \nu^*)$ 取最小值;
- ▶ 对于所有 $i = 1, \dots, m$, 有: $\lambda_i^* f_i(x^*) = 0$, 称为**互补松弛性**。

$$\lambda_i^* > 0 \Rightarrow f_i(x^*) = 0, \quad f_i(x^*) < 0 \Rightarrow \lambda_i^* = 0$$

Karush-Kuhn-Tucker (KKT) 条件

以下四个条件统称为 KKT 条件 (适用于 f_i, h_i 可微的优化问题):

1. 原始约束 (Primal constraints):
 $f_i(x) \leq 0, i = 1, \dots, m,$
 $h_i(x) = 0, i = 1, \dots, p$
2. 对偶可行性 (Dual constraints): $\lambda \geq 0$
3. 互补松弛性 (Complementary slackness): $\lambda_i f_i(x) = 0, i = 1, \dots, m$
4. 拉格朗日函数关于 x 的梯度为零 (Stationarity):

$$\nabla f_0(x) + \sum_{i=1}^m \lambda_i \nabla f_i(x) + \sum_{i=1}^p \nu_i \nabla h_i(x) = 0$$

若强对偶成立且 x, λ, ν 为最优解, 则它们必须满足 KKT 条件。

凸问题的 KKT 条件 (KKT Conditions for Convex Problem)

如果 $\tilde{x}, \tilde{\lambda}, \tilde{\nu}$ 满足一个凸优化问题的 KKT 条件, 则它们是最优解:

- ▶ 根据互补松弛性: $f_0(\tilde{x}) = L(\tilde{x}, \tilde{\lambda}, \tilde{\nu})$
- ▶ 根据第 4 条条件和凸性: $g(\tilde{\lambda}, \tilde{\nu}) = L(\tilde{x}, \tilde{\lambda}, \tilde{\nu})$

因此, 有:

$$f_0(\tilde{x}) = g(\tilde{\lambda}, \tilde{\nu})$$

若满足 **Slater 条件**, 则有: x 是最优的当且仅当存在 λ, ν 满足 KKT 条件。

- ▶ 回顾: Slater 条件意味着强对偶成立, 且对偶最优值是可达到的
- ▶ KKT 条件可视为无约束问题中 $\nabla f_0(x) = 0$ 的推广

示例: Water-filling 算法 (假设 $\alpha_i > 0$)

$$\begin{aligned} \min \quad & -\sum_{i=1}^n \log(x_i + \alpha_i) \\ \text{s.t.} \quad & x \geq 0, \quad \mathbf{1}^T x = 1 \end{aligned}$$

x 为最优当且仅当 $x \geq 0$, $\mathbf{1}^T x = 1$, 且存在 $\lambda \in \mathbb{R}^n, \nu \in \mathbb{R}$ 满足:


$$\lambda \geq 0, \quad \lambda_i x_i = 0, \quad \frac{1}{x_i + \alpha_i} + \lambda_i = \nu$$

- ▶ 若 $\nu < 1/\alpha_i$: $\lambda_i = 0, x_i = 1/\nu - \alpha_i$
- ▶ 若 $\nu \geq 1/\alpha_i$: $\lambda_i = \nu - 1/\alpha_i, x_i = 0$
- ▶ ν 由 $\mathbf{1}^T x = \sum_{i=1}^n \max\{0, 1/\nu - \alpha_i\} = 1$ 确定

示例：Water-filling 算法（假设 $\alpha_i > 0$ ）

解释 (Interpretation): 满足 $\sum_{i=1}^n \max\{0, 1/\nu - \alpha_i\} = 1$ 关系的 ν

- ▶ 总共 n 个槽位，第 i 个槽底高度为 α_i
- ▶ 用单位水量“灌入”该区域
- ▶ 最终水面高度为 $1/\nu^*$





目录

复习

问题重构

KKT 条件

灵敏度分析

扰动与敏感性分析 (Perturbation and Sensitivity Analysis)

$$\begin{array}{ll} \text{未扰动问题:} & \begin{array}{ll} \text{minimize} & f_0(x) \\ \text{subject to} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{array} \end{array} \qquad \begin{array}{ll} & \begin{array}{ll} \text{maximize} & g(\lambda, \nu) \\ \text{subject to} & \lambda \succeq 0 \end{array} \end{array}$$

$$\begin{array}{ll} \text{扰动问题:} & \begin{array}{ll} \text{minimize} & f_0(x) \\ \text{subject to} & f_i(x) \leq u_i, \quad i = 1, \dots, m \\ & h_i(x) = v_i, \quad i = 1, \dots, p \end{array} \end{array} \qquad \begin{array}{ll} & \begin{array}{ll} \text{maximize} & g(\lambda, \nu) - u^T \lambda - v^T \nu \\ \text{subject to} & \lambda \succeq 0 \end{array} \end{array}$$

- ▶ x 是原始变量, u, v 是扰动参数;
- ▶ $p^*(u, v)$ 表示扰动参数下的最优值;
- ▶ 我们关注的是: 能否从未扰动问题及其对偶解中, 得到关于 $p^*(u, v)$ 的有用信息。

全局敏感性分析结果 (Global Sensitivity Result)

假设未扰动问题满足强对偶性，且 λ^*, ν^* 是其对偶最优解。应用弱对偶性到扰动问题有：

$$p^*(u, v) \geq g(\lambda^*, \nu^*) - u^T \lambda^* - v^T \nu^*$$

$$(\text{假设原问题强对偶成立}) = p^*(0, 0) - u^T \lambda^* - v^T \nu^*$$

敏感性解释 (Sensitivity Interpretation):

- ▶ 若 λ_i^* 较大：当收紧约束 i (即 $u_i < 0$) 时， p^* 将显著上升
若 λ_i^* 较小：当放松约束 i (即 $u_i > 0$) 时， p^* 不会显著下降
- ▶ 若 ν_i^* 较大且为正：当取 $v_i < 0$ 时， p^* 显著上升；
若 ν_i^* 较大且为负：当取 $v_i > 0$ 时， p^* 显著上升
- ▶ 若 ν_i^* 较小且为正：当取 $v_i > 0$ 时， p^* 不会显著下降；
若 ν_i^* 较小且为负：当取 $v_i < 0$ 时， p^* 不会显著下降

局部敏感性 (Local Sensitivity)

如果 $p^*(u, v)$ 在 $(0, 0)$ 处可微, 则有:

$$\lambda_i^* = -\frac{\partial p^*(0, 0)}{\partial u_i}, \quad \nu_i^* = -\frac{\partial p^*(0, 0)}{\partial v_i}$$

证明 (以 λ_i^* 为例) 来自全局敏感性结果:

$$\frac{\partial p^*(0, 0)}{\partial u_i} = \lim_{t \searrow 0} \frac{p^*(te_i, 0) - p^*(0, 0)}{t} \geq -\lambda_i^*$$


$$\frac{\partial p^*(0, 0)}{\partial u_i} = \lim_{t \nearrow 0} \frac{p^*(te_i, 0) - p^*(0, 0)}{t} \leq -\lambda_i^*$$

因此, 两者相等, 得证。



局部敏感性 (Local Sensitivity)

图示说明： $p^*(u)$ 的函数图像（单个不等式约束）：



图中展示了： $p^*(u)$ 与其切线 $p^*(0) - \lambda^* u$ ，体现 λ^* 的几何意义。

示例：利润最大化问题

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & a^T x = b\end{array}$$

- ▶ 该问题可以表示为一个公司在资源使用水平为 b 的情况下使利润 $-f(x)$ 最大的问题;
- ▶ 公司希望研究在资源水平从 b 变为 $b + u$ 时 ($u > 0$ 使用更多资源, $u < 0$ 使用更少资源), 最优利润会如何变化。

形式假设：存在无间隙的最优原始解 x^* 和一个对偶解 $\lambda^* \in \mathbb{R}$, 且 f 是连续可微函数.

我们关注的是因水平 b 的微小变化而导致的最优值 $f(x^*)$ 的变化。

示例：利润的敏感性分析

$$\min f(x)$$

$$\text{s.t. } a^T x = b + u$$

- ▶ 设 $x^*(u)$ 为扰动问题的最优解；设 $\Delta x^* = x^*(u) - x^*$ 为最优解的变化；设 $\Delta f^* = f(x^*(u)) - f(x^*)$ 为最优值的变化；
- ▶ 根据 KKT 条件，有 $\nabla f(x^*) = -\nu^* a$ ；
- ▶ 使用泰勒一阶展开可得： $\Delta f^* = \nabla f(x^*)^T \Delta x^* + o(\|\Delta x^*\|) \approx -\nu^* a^T \Delta x^*$
- ▶ 由 $a^T x^* = b$ 且 $a^T x^*(u) = b + u$ 得： $a^T \Delta x^* = u \Rightarrow \Delta f^* \approx -\nu^* u$

微小扰动误差说明

$$\frac{\text{最优利润的变化}}{\text{资源水平的变化}} = \frac{\Delta f^*}{u} = -\nu^*$$

注：拉格朗日乘子 ν^* 表示单位资源水平变化对最优利润的影响率。