

优化理论与算法

第五章 凸问题

郭加熠 | 助理教授



目录

优化问题的标准形式

凸优化问题

拟凸优化问题

凸问题常见形式

优化问题的标准形式

优化问题的标准形式:

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

- ▶ $x \in \mathbb{R}^n$ 是优化变量
- ▶ $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$ 是目标函数
- ▶ $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ 是不等式约束函数
- ▶ $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$ 是等式约束函数
- ▶ $p^* = \inf \{f_0(x) \mid f_i(x) \leq 0, h_i(x) = 0\}$
- ▶ 若问题不可行: $p^* = \infty$
- ▶ 若问题在可行域内无下界: $p^* = -\infty$

最优解与局部最优解

- ▶ 若 $x \in \text{dom } f_0$ 且满足约束, 则 x 为**可行解**
- ▶ 若可行解 x 满足 $f_0(x) = p^*$, 则为**最优解**, 最优解集合记为 X_{opt}
- ▶ 若存在 $R > 0$, 使 x 在以下问题中为最优解, 则称其为**局部最优解**:

$$\begin{aligned} \min_z \quad & f_0(z) \\ \text{s.t.} \quad & f_i(z) \leq 0, \quad i = 1, \dots, m \\ & h_i(z) = 0, \quad i = 1, \dots, p \\ & \|z - x\|_2 \leq R \end{aligned}$$

- ▶ $f_0(x) = 1/x$, $\text{dom } f_0 = \mathbb{R}_{++}$:
 $p^* = 0$, 无最优解
- ▶ $f_0(x) = x \log x$, $\text{dom } f_0 = \mathbb{R}_{++}$:
 $p^* = -1/e$, $x = 1/e$ 是最优解
- ▶ $f_0(x) = -\log x$, $\text{dom } f_0 = \mathbb{R}_{++}$:
 $p^* = -\infty$
- ▶ $f_0(x) = x^3 - 3x$: $p^* = -\infty$,
但 $x = 1$ 是局部最优解

隐式约束 (Implicit Constraints)

标准形式的优化问题包含隐式约束：

$$x \in \mathcal{D} = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=1}^p \text{dom } h_i$$

- ▶ \mathcal{D} 被称为问题的定义域 (domain)
- ▶ $f_i(x) \leq 0$, $h_i(x) = 0$ 是显式约束
- ▶ 若 $m = p = 0$, 即无显式约束, 则问题为无约束问题 (unconstrained)

例子：

$$\min f_0(x) = - \sum_{i=1}^k \log(b_i - a_i^\top x)$$

这是一个无约束问题, 但其隐式约束为 $a_i^\top x < b_i$

可行性问题 (Feasibility Problem)

Find x

$$\text{s.t. } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$h_i(x) = 0, \quad i = 1, \dots, p$$

可行性问题是目标函数为常数 $f_0(x) = 0$ 的一般优化问题特例:

$$\min \quad 0$$

$$\text{s.t. } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$h_i(x) = 0, \quad i = 1, \dots, p$$

- ▶ 若约束可行, 则 $p^* = 0$, 任意可行 x 为最优
- ▶ 若约束不可行, 则 $p^* = \infty$



目录

优化问题的标准形式

凸优化问题

拟凸优化问题

凸问题常见形式



凸优化问题 (Convex Optimization Problem)

标准形式:

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & a_i^\top x = b_i, \quad i = 1, \dots, p \end{aligned}$$

- ▶ f_0, f_1, \dots, f_m 是凸函数, 等式约束是仿射的
- ▶ 若 f_0 为拟凸函数, f_1, \dots, f_m 为凸函数, 则问题为拟凸优化问题

常写作:

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & Ax = b \end{aligned}$$

重要性质: 凸优化问题的可行解集是凸集



非凸约束示例

$$\begin{array}{ll}\min & f_0(x) = x_1^2 + x_2^2 \\ \text{s.t.} & f_1(x) = \frac{x_1}{1 + x_2^2} \leq 0\end{array}$$

$$h_1(x) = (x_1 + x_2)^2 = 0$$

- ▶ f_0 是凸函数；可行域 $\{(x_1, x_2) \mid x_1 = -x_2 \leq 0\}$ 是凸集
- ▶ 不是凸优化问题： f_1 非凸， h_1 非仿射
- ▶ 它等价（但不完全相同）于下列凸优化问题：

$$\begin{array}{ll}\min & x_1^2 + x_2^2 \\ \text{s.t.} & x_1 \leq 0 \\ & x_1 + x_2 = 0\end{array}$$



局部最优与全局最优

任意凸优化问题的局部最优点也是全局最优点。

证明：假设 x 是局部最优，但存在可行 y 使得 $f_0(y) < f_0(x)$ 。

局部最优意味着存在 $R > 0$ ，使得

$$z \text{ 可行}, \|z - x\|_2 \leq R \Rightarrow f_0(z) \geq f_0(x)$$

令 $z = \theta y + (1 - \theta)x$ ，不妨设 $\theta = R/(2\|y - x\|_2)$ ，那么可以验证：

$$\|y - x\|_2 > R \Rightarrow 0 < \theta < 1/2 \in (0, 1), \text{ 且 } \|z - x\|_2 = R/2.$$

由目标函数凸性可得： $f_0(z) \leq \theta f_0(y) + (1 - \theta)f_0(x) < f_0(x)$

这与 x 是局部最优点矛盾，故 x 必为全局最优点。

可微函数的最优性判据


若目标函数 f_0 可微，点 x 是最优的当且仅当：

- ▶ x 是可行解；
- ▶ 对所有可行点 y ，有：

$$\nabla f_0(x)^T (y - x) \geq 0$$

图示说明：

- ▶ 若 $\nabla f_0(x) \neq 0$ ，则其定义了一个在点 x 处支撑可行域 X 的超平面 (supporting hyperplane)



常见结构下的最优性条件

1. 无约束问题: $\min f_0(x)$, 则最优的充要条件为:

$$\nabla f_0(x) = 0$$

2. 等式约束问题: $\min f_0(x)$ s.t. $Ax = b$ 。最优性充要条件为存在 ν 使得:

$$x \in \text{dom } f_0, \quad Ax = b, \quad \nabla f_0(x) + A^T \nu = 0$$

3. 非负正交域上的最优化: $\min f_0(x)$ s.t. $x \succeq 0$ 。最优性充要条件为:

$$x \in \text{dom } f_0, \quad x \succeq 0, \quad \begin{cases} \nabla f_0(x)_i \geq 0 & \text{若 } x_i = 0 \\ \nabla f_0(x)_i = 0 & \text{若 } x_i > 0 \end{cases}$$

等价凸优化问题：消除等式约束

若两个问题的解可相互转换，我们称它们等价。

目标：消除等式约束 $Ax = b$ ，保持凸性不变。

原问题：

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & Ax = b \end{aligned}$$

等价于如下问题（变量变为 z ）：

$$\begin{aligned} \min \quad & f_0(Fz + x_0) \\ \text{s.t.} \quad & f_i(Fz + x_0) \leq 0, \quad i = 1, \dots, m \end{aligned}$$

其中 F 和 x_0 满足： $Ax = b \iff x = Fz + x_0$, for some z



等价凸问题：引入等式

引入等式约束：

$$\begin{aligned} \min \quad & f_0(A_0x + b_0) \\ \text{s.t.} \quad & f_i(A_ix + b_i) \leq 0, \quad i = 1, \dots, m \end{aligned}$$

等价于引入变量 $y_i = A_ix + b_i$ ：

$$\begin{aligned} \min_{x, y_i} \quad & f_0(y_0) \\ \text{s.t.} \quad & f_i(y_i) \leq 0, \quad i = 1, \dots, m \\ & y_i = A_ix + b_i, \quad i = 0, \dots, m \end{aligned}$$



等价凸问题：引入松弛变量

引入松弛变量：

$$\min \quad f_0(x) \quad \text{s.t.} \quad a_i^T x \leq b_i, \quad i = 1, \dots, m$$

等价于：

$$\begin{aligned} \min_{x,s} \quad & f_0(x) \\ \text{s.t.} \quad & a_i^T x + s_i = b_i, \quad i = 1, \dots, m \\ & s_i \geq 0, \quad i = 1, \dots, m \end{aligned}$$

等价凸优化形式：改写成上图形式

凸问题标准形式问题：

$$\min f_0(x) \quad \text{s.t.} \quad f_i(x) \leq 0, \quad Ax = b$$

等价于引入变量 t 的形式：

$$\begin{aligned} \min_{x,t} \quad & t \\ \text{s.t.} \quad & f_0(x) - t \leq 0 \\ & f_i(x) \leq 0 \\ & Ax = b \end{aligned}$$

等价凸优化形式：对部分变量先进行最小化

原问题

$$\min_{x_1, x_2} f_0(x_1, x_2) \quad \text{s.t.} \quad f_i(x_1) \leq 0$$

等价于令 $\tilde{f}_0(x_1) = \min_{x_2} f_0(x_1, x_2)$

$$\min_{x_1} \tilde{f}_0(x_1) \quad \text{s.t.} \quad f_i(x_1) \leq 0,$$

含义：先优化掉 x_2 ，之后仅对 x_1 优化。

- **降维**：减少优化变量数量；
- **结构优化**：保留部分变量结构，有利于分布式算法（如 ADMM）实现。



目录

优化问题的标准形式

凸优化问题

拟凸优化问题

凸问题常见形式




拟凸优化问题 (Quasiconvex Optimization)

$$\begin{array}{ll}\min & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & Ax = b\end{array}$$

其中:

- ▶ $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$ 是拟凸函数;
- ▶ f_1, \dots, f_m 是凸函数;
- ▶ $Ax = b$ 是仿射约束。



图示：拟凸函数可能出现“鞍点式”的局部最优，见右图。

拟凸函数的下水平集的凸表示

若 $f_0(x)$ 是拟凸函数, 则存在一族函数 $\phi_t(x)$ 满足:

- ▶ 对每个固定的 t , $\phi_t(x)$ 是凸函数; 同时, $f_0(x) \leq t \iff \phi_t(x) \leq 0$

示例: 设 $f_0(x) = \frac{p(x)}{q(x)}$, 其中:

- ▶ $p(x)$ 是凸函数, $p(x) \geq 0$
- ▶ $q(x)$ 是凹函数, $q(x) > 0$

令:

$$\phi_t(x) = p(x) - tq(x)$$

则当 $t \geq 0$ 时, ϕ_t 是凸函数, 且有:

$$f_0(x) \leq t \iff \phi_t(x) \leq 0$$

拟凸优化：通过凸可行性问题 + 二分法求解

将拟凸优化转化为可行性问题：固定参数 t ，考虑以下凸可行性问题

$$\phi_t(x) \leq 0, \quad f_i(x) \leq 0, \quad Ax = b \quad (1)$$

► 若 (1) 可行，则 $t \geq p^*$

► 若 (1) 不可行，则 $t < p^*$

二分法 (bisection method):

► 输入： $l \leq p^*$, $u \geq p^*$, $\epsilon > 0$

► 重复直到 $u - l \leq \epsilon$:

1. $t := (l + u)/2$

2. 解可行性问题 (1)

3. 若可行，设 $u := t$; 否则 $l := t$

收敛次数:

$$\left\lceil \log_2 \left(\frac{u - l}{\epsilon} \right) \right\rceil$$



目录

优化问题的标准形式

凸优化问题

拟凸优化问题


凸问题常见形式

线性规划 (Linear Program, LP)

$$\min \quad c^T x + d$$

$$\text{s.t.} \quad Gx \leq h$$

$$Ax = b$$



- ▶ 具有仿射目标函数与仿射约束函数的凸优化问题
- ▶ 可行解集合是一个多面体 (polyhedron)



示例 (Examples)

饮食问题 (diet problem): 选择 x_1, \dots, x_n 种食物的数量

- ▶ 每单位食物 j 的价格为 c_j , 含有 a_{ij} 单位的营养素 i
- ▶ 健康饮食要求营养素 i 的摄入量至少为 b_i

为找到最便宜的健康饮食方案, 求解如下问题:

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & Ax \leq b \\ & x \geq 0 \end{aligned}$$



Chebyshev 中心 (Chebyshev center of a polyhedron)

Chebyshev 中心定义于:

$$\mathcal{P} = \{x \mid a_i^T x \leq b_i, \quad i = 1, \dots, m\}$$

是其最大内切球的中心, 记为: $\mathcal{B} = \{x_c + u \mid \|u\|_2 \leq r\}$

► $a_i^T x \leq b_i$ 对所有 $x \in \mathcal{B}$ 成立, 当且仅当:


$$\sup\{a_i^T (x_c + u) \mid \|u\|_2 \leq r\} = a_i^T x_c + r\|a_i\|_2 \leq b_i$$

► 因此, 可以通过求解以下线性规划来确定 x_c, r :

$$\begin{aligned} \max \quad & r \\ \text{s.t.} \quad & a_i^T x_c + r\|a_i\|_2 \leq b_i, \quad i = 1, \dots, m \end{aligned}$$

二次规划 (Quadratic Program, QP)

$$\begin{aligned} \min \quad & \frac{1}{2}x^T Px + q^T x + r \\ \text{s.t.} \quad & Gx \leq h \\ & Ax = b \end{aligned}$$



- ▶ 要求 $P \in \mathbb{S}_+^n$, 所以目标函数是凸二次函数
- ▶ 目标是在多面体可行域上最小化一个凸二次函数

示例：最小二乘与随机成本线性规划

最小二乘 (least-squares) $\min \|Ax - b\|_2^2$

- ▶ 解析解 $x^* = A^\dagger b$, 其中 A^\dagger 是广义逆
- ▶ 可添加线性约束, 例如 $l \leq x \leq u$

具有随机成本的线性规划 (linear program with random cost)

$$\begin{aligned} \min \quad & \bar{c}^T x + \gamma x^T \Sigma x = \mathbb{E}[c^T x] + \gamma \text{Var}(c^T x) \\ \text{s.t.} \quad & Gx \leq h, \quad Ax = b \end{aligned}$$

- ▶ 向量 c 是具有均值 \bar{c} 、协方差为 Σ 的随机向量
- ▶ 因此 $c^T x$ 是具有均值 $\bar{c}^T x$ 、方差 $x^T \Sigma x$ 的随机变量
- ▶ $\gamma > 0$ 是风险规避参数, 调节期望成本与方差 (风险) 之间的权衡

带二次约束的二次规划 (QCQP)

$$\begin{aligned} \min \quad & \frac{1}{2}x^T P_0 x + q_0^T x + r_0 \\ \text{s.t.} \quad & \frac{1}{2}x^T P_i x + q_i^T x + r_i \leq 0, \quad i = 1, \dots, m \\ & Ax = b \end{aligned}$$

- ▶ 要求 $P_i \in \mathbb{S}_+^n$, 所以目标函数与约束均为凸二次函数
- ▶ 要求 $P_1, \dots, P_m \in \mathbb{S}_{++}^n$, 所以可行域是 m 个椭球与一个仿射集的交集



二阶锥规划 (Second-order Cone Programming)

$$\begin{aligned} \min \quad & f^T x \\ \text{s.t.} \quad & \|A_i x + b_i\|_2 \leq c_i^T x + d_i, \quad i = 1, \dots, m \\ & Fx = g \end{aligned}$$

其中 $A_i \in \mathbb{R}^{n_i \times n}$, $F \in \mathbb{R}^{p \times n}$

- ▶ 不等式为二阶锥 (second-order cone, SOC) 约束, 也可以表示为:

$$(A_i x + b_i, c_i^T x + d_i) \in n_i + 1 \text{ 维的二阶锥}$$

- ▶ 若 $n_i = 0$, 则退化为线性规划; 若 $c_i = 0$, 则退化为 QCQP
- ▶ 比 QCQP 和 LP 更一般

鲁棒线性规划 (Robust Linear Programming)

优化问题中的参数常常具有不确定性，例如在线性规划中：

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & a_i^T x \leq b_i, \quad i = 1, \dots, m \end{aligned}$$

其中 c , a_i , b_i 都可能具有不确定性。

我们以 a_i 为例，常见的两种建模方式：

- **确定性模型**：约束对所有可能的 $a_i \in \mathcal{E}_i$ 都必须成立

$$\min \quad c^T x \quad \text{s.t.} \quad a_i^T x \leq b_i \quad \forall a_i \in \mathcal{E}_i, \quad i = 1, \dots, m$$

- **随机模型**： a_i 是随机变量，约束以概率 η 成立

$$\min \quad c^T x \quad \text{s.t.} \quad \text{prob}(a_i^T x \leq b_i) \geq \eta, \quad i = 1, \dots, m$$

确定性鲁棒优化中的 SOCP 表达

- 对于不确定集 \mathcal{E}_i , 选用椭球形式:

$$\mathcal{E}_i = \{\bar{a}_i + P_i u \mid \|u\|_2 \leq 1\}, \quad \bar{a}_i \in \mathbb{R}^n, \quad P_i \in \mathbb{R}^{n \times n}$$

中心为 \bar{a}_i , 半轴由 P_i 的奇异值与奇异向量决定

- 鲁棒线性规划问题:

$$\min c^T x \quad \text{s.t.} \quad a_i^T x \leq b_i, \quad \forall a_i \in \mathcal{E}_i, \quad i = 1, \dots, m$$

可等价转化为二阶锥规划:

$$\min c^T x \quad \text{s.t.} \quad \bar{a}_i^T x + \|P_i^T x\|_2 \leq b_i, \quad i = 1, \dots, m$$

(推导基于: $\sup_{\|u\|_2 \leq 1} (\bar{a}_i + P_i u)^T x = \bar{a}_i^T x + \|P_i^T x\|_2$)

随机鲁棒优化中的 SOCP 表达

- ▶ 假设 $a_i \sim \mathcal{N}(\bar{a}_i, \Sigma_i)$, 均值为 \bar{a}_i , 协方差为 Σ_i
- ▶ 则 $a_i^T x$ 是正态分布随机变量, 均值为 $\bar{a}_i^T x$, 方差为 $x^T \Sigma_i x$
- ▶ 因此概率约束可写为: $\text{prob}(a_i^T x \leq b_i) = \Phi\left(\frac{b_i - \bar{a}_i^T x}{\|\Sigma_i^{1/2} x\|_2}\right)$

其中 $\Phi(x) = (1/\sqrt{2\pi}) \int_{-\infty}^x e^{-t^2/2} dt$ 为标准正态分布的累积分布函数

- ▶ 鲁棒线性规划问题:

$$\min c^T x \quad \text{s.t.} \quad \text{prob}(a_i^T x \leq b_i) \geq \eta, \quad i = 1, \dots, m$$

当 $\eta \geq 1/2$ 时, 可转化为 SOCP:

$$\min c^T x \quad \text{s.t.} \quad \bar{a}_i^T x + \Phi^{-1}(\eta) \|\Sigma_i^{1/2} x\|_2 \leq b_i, \quad i = 1, \dots, m$$



半正定规划 (Semidefinite Program, SDP)

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & x_1 F_1 + x_2 F_2 + \cdots + x_n F_n + G \preceq 0 \\ & Ax = b \end{aligned}$$

其中给定参数为: c, A, b 以及 $F_i, G \in \mathbb{S}^k$; 决策变量: $x \in \mathbb{R}^n$

- ▶ 不等式约束被称为线性矩阵不等式
- ▶ 多个不等式, 如: $x_1 \hat{F}_1 + \cdots + x_n \hat{F}_n + \hat{G} \preceq 0, \quad x_1 \tilde{F}_1 + \cdots + x_n \tilde{F}_n + \tilde{G} \preceq 0$

等价于单个:
$$x_1 \begin{bmatrix} \hat{F}_1 & 0 \\ 0 & \tilde{F}_1 \end{bmatrix} + x_2 \begin{bmatrix} \hat{F}_2 & 0 \\ 0 & \tilde{F}_2 \end{bmatrix} + \cdots + x_n \begin{bmatrix} \hat{F}_n & 0 \\ 0 & \tilde{F}_n \end{bmatrix} + \begin{bmatrix} \hat{G} & 0 \\ 0 & \tilde{G} \end{bmatrix} \preceq 0$$



LP 与 SOCP 的 SDP 表达

LP 与等价 SDP

- ▶ LP: $\min c^T x \quad \text{s.t.} \quad Ax \leq b$
- ▶ SDP: $\min c^T x \quad \text{s.t.} \quad \text{diag}(Ax - b) \preceq 0$

SOCP 与等价 SDP

- ▶ SOCP: $\min f^T x \quad \text{s.t.} \quad \|A_i x + b_i\|_2 \leq c_i^T x + d_i, \quad i = 1, \dots, m$
- ▶ SDP:

$$\min f^T x \quad \text{s.t.} \quad \begin{bmatrix} (c_i^T x + d_i)I & A_i x + b_i \\ (A_i x + b_i)^T & c_i^T x + d_i \end{bmatrix} \succeq 0, \quad i = 1, \dots, m$$



特征值最小化问题 (Eigenvalue Minimization)

$$\begin{aligned} \min \quad & \lambda_{\max}(A(x)) \\ \text{s.t.} \quad & A(x) = A_0 + x_1 A_1 + \cdots + x_n A_n, \quad A_i \in \mathbb{S}^k \end{aligned}$$

等价的 SDP 形式:

$$\min t \quad \text{s.t.} \quad A(x) \preceq tI$$

- ▶ 决策变量为 $x \in \mathbb{R}^n, t \in \mathbb{R}$
- ▶ 推理基于:

$$\lambda_{\max}(A) \leq t \iff A \preceq tI$$